

《用于图像超分辨率的摊销 MAP 推断》

数学前置 · 学习资源指南

Amortised MAP Inference for Image Super-Resolution (AffGAN) — Study Resources

按「概率推断 → 信息论散度 → 线性代数投影 → score/采样 → 进阶」五条主线组织
每条资源标注「类型 / 难度 / 对应论文章节」，链接均已核实

如何使用本指南。 资源按「先建直觉 → 再补数学 → 最后看原始论文」的顺序排列。每个主题先给 1 个**首选入门**（★），再给若干补充。难度标记：入门 看完建直觉，进阶 含推导，原始 是论文/经典原文。
一个彩蛋。 主题四「高维几何」的核心资源——“高维高斯像肥皂泡”——正是出自本论文作者之一 **Ferenc Huszar** 的博客；这也解释了论文 5.6 节为何特别讨论“众数在高维下高度非典型”。读它等于直接听作者讲课。

学习路线总表

顺序	主题（学完能看懂论文哪部分）	建议时长	对应章节
1	贝叶斯点估计 — MAP / MLE / 后验均值的区别（看懂 Figure 1）	1-2 天	§ 3, 式(2)-(4)
2	信息论散度 — 熵 / 交叉熵 / KL（理解训练目标 式 9）	1-2 天	§ 3.2, 式(9)(10)
3	线性代数投影 — 伪逆 / 零空间 / 正交投影（本文核心创新）	2-3 天	§ 3.1, 附录 B
4	score 与去噪 — “去噪 = 估计 log 密度梯度”（式 12）	2-3 天	§ 3.3, 式(12)
5	GAN 理论 + 变分推断 — 最优判别器、ELBO（附录 A/F）	2-3 天	§ 3.2, 附录 A/F
★	高维几何（选学） — 测度集中 / 肥皂泡（5.6 节的批评）	半天	§ 5.6

注：若时间紧张，优先级最高为主题 1、3、4 —— 分别撑起论文的“动机、架构创新、核心算法”。

主题一 · 贝叶斯点估计（MAP / MLE / 后验均值）

📌 对应论文：§ 3 式(2)-(4)。理解“为什么 MSE 解=后验均值→模糊，而 MAP 解=众数→清晰”，看懂 Figure 1 的全部标注。

★ **MLE vs MAP：两者的数学联系** 博客 入门→进阶

<https://agustinus.kristia.de/blog/mle-vs-map/>

Agustinus Kristiadi 的博客。最干净地讲清 MAP 与 MLE 只差一个“先验项”，且 MLE 就是“无信息先验下的 MAP”。公式少而精，适合第一篇读。

Full Explanation of MLE, MAP and Bayesian Inference 博客 入门

<https://towardsdatascience.com/full-explanation-of-mle-map-and-bayesian-inference-1db9a7fb1d2b/>

用抛硬币例子把三者从直觉到数值全部走一遍，并点明关键：MLE/MAP 给“点估计”，完整贝叶斯给“整条后验分布”——正是论文从“点估计”转向“采样”（5.6 节）的伏笔。

The Intuition behind MLE and MAP (NBA 类比) 博客 入门

<https://medium.com/@devcharlie2698619/the-intuition-behind-maximum-likelihood-estimation-mle-and-maximum-a-posteriori-estimation-map-b8ba1ba1078f>

用“新手 vs 老练的 NBA 分析师”类比 MLE 与 MAP：MLE 易被一波手感带偏，MAP 用先验把估计拉回合理区间。记忆点强，适合建直觉。

教材：Bishop 《Pattern Recognition and Machine Learning》第 1-2 章 教材 进阶

<https://www.microsoft.com/en-us/research/publication/pattern-recognition-machine-learning/>

系统理解“点估计随损失函数而变”（平方损失→均值、绝对损失→中位数、0-1 损失→众数）的权威来源。这正是 Figure 1 三个估计量差异的根。

主题二 · 信息论：熵 / 交叉熵 / KL 散度

📌 对应论文：§ 3.2 式(9)(10)。核心是恒等式 $H[q, p] - \text{KL}[q||p] = H[q]$ ——论文用它解释“AffGAN 为何偏好高熵、更多样的解”。

★ Generative Modeling 之前必看：交叉熵的编码直觉 博客 入门

<https://ramsane.github.io/articles/cross-entropy-explained-with-entropy-and-kl-divergence/>

用“用错误的编码表发消息要多花几个 bit”来解释 $\text{KL} = \text{交叉熵} - \text{熵}$ 。是把信息论“翻译成人话”的最佳入口。

Information Theory Fundamentals (含交互式可视化) 博客 入门→进阶

<https://nimasarang.com/blog/2024-08-24-information-theory/>

熵、交叉熵、KL、以及 Jensen-Shannon 散度（GAN 原始理论的量）一站式覆盖，带交互图和证明。还讲了 forward KL vs reverse KL 的差别——理解 GAN/变分推断模式行为的关键。

Cross-entropy and KL divergence — Eli Bendersky 博客 进阶

<https://eli.thegreenplace.net/2025/cross-entropy-and-kl-divergence/>

偏数学但极清晰。明确点出“因为真实分布的熵 $H(P)$ 与模型无关，所以最小化交叉熵 $\Leftrightarrow$ 最小化 KL”——这正是论文式(9)把 MAP 目标写成交叉熵的依据。

Kullback-Leibler divergence — Wikipedia 参考 原始

https://en.wikipedia.org/wiki/Kullback%E2%80%93Leibler_divergence

作工具书查阅：KL 的非对称性、与 Bregman 散度的关系（附录 C 会用到）、链式法则分解（附录 F 用到）。

主题三 · 线性代数：伪逆 / 零空间 / 正交投影

📌 对应论文：§ 3.1 式(7) + 附录 B。本文最硬核的创新——仿射投影层 $\Pi_x^A f = (I - A^+ A)f + A^+ x$ 。必须懂： $(I - A^+ A)$ 是到 A 零空间的投影，故残差下采样恒为 0。

★ 3Blue1Brown 《线性代数的本质》第 7 章：列空间与零空间 视频 入门

<https://www.youtube.com/watch?v=uQhTuRIWMxw>

Grant Sanderson 用动画讲清 column space（值域/像）与 null space（核/零空间）的几何含义。看懂这一集，式(7)的“残差落在零空间→下采样必为 0”就一目了然。

3Blue1Brown 《线性代数的本质》完整播放列表 视频 入门

https://www.youtube.com/playlist?list=PLZHQObOWTQDPD3MizzM2xVFitgF8hE_ab

共 15 集。若线代基础薄弱，建议至少看第 3（线性变换）、7（列/零空间）、9（点积与对偶）、13（基变换）集。视觉优先，几乎不需要预备知识。

The Moore-Penrose Pseudoinverse (UCLA Math 33A, Laub 讲义) 讲义 进阶

<https://www.math.ucla.edu/~laub/33a.2.12s/mppseudoinverse.pdf>

伪逆 A^+ 的四条定义性质 ($AA^+A = A$ 等) 与 SVD 构造法的简洁 PDF 讲义。论文式(7) 反复用到这些性质。

Moore-Penrose Pseudoinverse 与投影矩阵 博客 进阶

<https://seanie12.github.io/blog/linear%20algebra/pseudo-inverse/>

重点讲“ AA^+ 与 A^+A 都是正交投影矩阵”这一关键事实——这正是仿射投影层能保证输入输出一致性的数学根源。

教材：Strang 《Introduction to Linear Algebra》(四个基本子空间) 教材 进阶

<https://math.mit.edu/~gs/linearalgebra/>

若想真正吃透“行空间/列空间/零空间/左零空间”四个基本子空间与最小二乘的关系（附录 B 的伪逆数值估计就是最小二乘思想），Strang 是黄金标准。配套 MIT 18.06 公开课视频。

主题四 · score 函数与去噪（“去噪 = 估计梯度”）

📌 对应论文：§ 3.3 式(12): $(f^*(y) - y)/\sigma^2 \approx \nabla_y \log p_Y(y)$ 。AffDG 方法的全部理论依据，也是当今扩散模型的同源思想。

★ Yang Song: Generative Modeling by Estimating Gradients of the Data Distribution

博客 入门→进阶

<https://yang-song.net/blog/2021/score/>

score-based 模型的权威科普长文。把 score function = log 密度的梯度、denoising score matching、Langevin 采样 串成一条线，配大量动图。读懂它，论文式(11)(12) 的去噪引导就彻底通了。（强烈推荐，本主题首选）

Yang Song: Sliced Score Matching 博客 进阶

<https://yang-song.net/blog/2019/ssm/>

讲 score matching 如何绕开难以计算的配分函数，只匹配 score。理解“为什么不需要显式知道先验 p_Y 就能拿到梯度”。

Denoising Score Matching 详解（含推导） 博客 进阶

<https://johfischer.com/2022/09/18/denoising-score-matching/>

一步步推导“加高斯噪声去噪”与“匹配 score”的等价性。是论文式(12) 那个约等号的完整证明版。

原始论文：Vincent (2011) A Connection Between Score Matching and Denoising Autoencoders 论文 原始

https://www.iro.umontreal.ca/~vincentp/Publications/smdae_techreport.pdf

论文式(12) 直接引用的源头 (Vincent, 2011)。证明了贝叶斯最优去噪器隐含数据 log 概率的梯度。想追根溯源必读。

主题五 · GAN 理论与变分推断

📌 对应论文：§ 3.2 + 附录 A（最优判别器 $D^* = p_Y/(p_Y + q_G)$ 、与 KL/JS 的联系）；附录 F（把随机版 AffGAN 解释为变分推断）。

★ Lilian Weng: From GAN to WGAN 博客 入门→进阶

<https://lilianweng.github.io/posts/2017-08-20-gan/>

GAN 理论的最佳中文友好讲解（英文）。完整推导最优判别器、并说明在最优判别器下 GAN 目标 = 最小化 JS 散度。还点出 GAN 不稳定源于“高维下两分布支撑集不相交”——这正是论文附录 C 实例噪声要解决的问题。亦有 arXiv 版 (1904.08994)。

原始论文: Goodfellow et al. (2014) Generative Adversarial Nets 论文 原始

<https://arxiv.org/abs/1406.2661>

GAN 开山之作。论文式(10) 与附录 A 的更新规则都建立在它之上。看第 3-4 节的极小极大博弈与最优判别器证明。

Lilian Weng: Flow-based / VAE 等生成模型综述 博客 进阶

<https://lilianweng.github.io/posts/2018-10-13-flow-models/>

理解附录 F “摊销变分推断”的背景：为何 $p(x) = \int p(x|z)p(z) dz$ 难算、变分推断如何用 ELBO 绕开。

Tutorial #5: Variational Autoencoders (RBC Borealis) 博客 入门→进阶

<https://rbcborealis.com/research-blogs/tutorial-5-variational-auto-encoders/>

ELBO 与“重建损失 + KL 正则”的直觉解释，并讲清 VAE 与 EM 算法的关系。论文附录 F 把 AffGAN 类比为 VAE，读此打底最顺。

原始论文: Kingma & Welling (2014) Auto-Encoding Variational Bayes 论文 原始

<https://arxiv.org/abs/1312.6114>

VAE 原文，论文附录 F 直接对标的工作。重点看 ELBO 推导与重参数化技巧。

主题六（选学）· 高维几何：测度集中与“肥皂泡”

📌 对应论文：§ 5.6 的批评：“高维标准高斯的典型样本范数 $\approx \sqrt{d}$ ，而众数范数为 0，故众数高度非典型”——这是质疑纯 MAP、转向后验采样的关键论据。

★ Why High-Dimensional Gaussians Feel Like Soap Bubbles 博客 入门

<https://rd.me/typicality-soap-bubble>

用“肥皂泡”比喻讲透测度集中：高维高斯的概率质量几乎全在一层薄壳上，而密度最高的原点反而几乎没有样本。直接对应论文 5.6 节的论证。（该比喻源自本文作者 Ferenc Huszár 的博客 inFERENCe）

The Counterintuitive Behavior of High-Dimensional Gaussians — Mianzhi Wang 博客

进阶

<https://research.wmz.ninja/articles/2018/03/the-counterintuitive-behavior-of-high-dimensional-gaussian-distributions.html>

带 Gaussian Annulus Theorem（高斯环带定理）的较严格版本，量化“99% 质量集中在薄壳”的现象。想要数学保证看这篇。

The unintuitive nature of high-dimensional spaces 博客 进阶

<https://andrewcharlesjones.github.io/journal/high-dim-gaussians.html>

从“密度 vs 体积”的竞争角度解释悖论：虽然原点密度最高，但远离均值处体积大得多，质量被挤到中间的窄带。配模拟代码，便于动手验证。

学完后的建议路径。① 先用 1 周过完主题 1-2 (概率 + 信息论)，同时配 3B1B 线代视频热身；② 第 2 周攻主题 3-4 (伪逆投影 + score)，这是论文的技术核心；③ 第 3 周读附录 A/F 与 GAN/VAE 原文，回看译文里的“译者注”对照理解；④ 最后重读论文 Figure 1 与 5.6 节，检验是否真的打通“MAP→交叉熵→投影→GAN”这条主线。