

用于图像超分辨率的 摊销 MAP 推断

Amortised MAP Inference for Image Super-Resolution (AffGAN)

Casper Kaae Sønderby^{1,2} · Jose Caballero¹ · Lucas Theis¹ · Wenzhe Shi¹ · Ferenc Huszár¹

¹ Twitter (伦敦) ² 哥本哈根大学

全文一条主线：MAP → 仿射投影 → 交叉熵 → 三种解法

本稿把整篇论文“讲”一遍：脉络 → 意译 → 批注 → 拆公式

配套：AffGAN_zh.pdf (逐句译文) · index.html (幻灯片) · 快速入门.html (冲刺手册)

如何使用本稿

本稿按论文原有章节推进，但每一节都被重新组织成四层：先用一个🧠 **脉络框**告诉你“这节要解决什么、在主线上处于哪一步”；再用**原文大意框**把这一节的内容用中文意译讲清（不是逐句直译，逐句对照请翻 AffGAN_zh.pdf）；随后穿插四类批注；关键公式一律按论文编号引用并逐符号拆开。

五类批注框的分工：

■ **术语卡** ▶ **术语卡**：第一次出现的概念在这里解释，不用往前翻。已经懂的直接跳过。

🔍 **逐项拆解** ▶ **逐项拆解**：公式逐符号讲，推导补全论文跳过的中间步骤。第一遍读可跳过，第二遍必读。

💡 **人话直觉** ▶ **人话直觉**：一句话版本。如果拆解框看晕了，回来读这里。

⚠️ **易错点** ▶ **易错点**：最容易理解错、或讲论文时最容易说错的地方（部分条目来自对照原文逐句核验的勘误）。

🔗 **延伸** ▶ **延伸**：与后续文献（如扩散模型）的联系，读不读不影响理解论文。

建议的三遍读法：第一遍只读每节的脉络框+人话框+原文大意（约 40 分钟，建立骨架）；第二遍加读拆解框和易错点（重点在 §3，这一章占全文难度的七成）；第三遍带着文末“自测清单”回来检验，答不上的回到对应节。正文中的 ▶ **幻灯片 12** 标签指向配套幻灯片 index.html 的页码，讲稿排练时可对照。

全文主线（背下来）

- ① **MAP**：超分是多解问题，MSE 取“平均”必然糊，改取后验**众数**；
- ② **仿射投影**：用结构（而非损失项）把“输出下采样后必须等于输入”焊死，约束优化变无约束；
- ③ **交叉熵**：于是“摊销 MAP”恰好等价于最小化模型输出分布与真实图像分布的交叉熵 $H[q_\theta, p_Y]$ ，超分变成生成式建模，不再需要成对数据；
- ④ **三种解法**：交叉熵没法直接算 → 用 GAN（AffGAN）、去噪梯度（AffDG）、显式密度（AffLL）三种方式逼近，实验中 AffGAN 胜出。

目 录

如何使用本稿	2
第 0 站 · 标题拆解与摘要精读	4
标题四个词，就是论文的全部承诺	4
摘要的信息结构	4
第 1 站 · §1 引言：为什么放弃 MSE、转向 MAP	4
1.1 欠定逆问题与“平均必糊”	5
1.2 为什么不直接换“感知损失”	5
1.3 Figure 1：全文题眼，务必读透	5
1.4 引言承诺的两大贡献	6
第 2 站 · §2 相关工作：本文站在哪三条线的交点上	6
第 3 站 · §3 理论：从 MAP 到交叉熵的完整推导	7

3.0 从经验风险到摊销 MAP (式 1-4)	7
3.1 处理似然项: 仿射投影层 (式 5-7)	8
3.1 续: 化归交叉熵 (式 8-9) —— 全文最漂亮的一步	9
3.2 武器一 · AffGAN: 仿射投影 + 修正更新规则 (式 10)	10
3.2.1 实例噪声: GAN 为什么不稳、怎么救 (式 26)	10
3.3 武器二 · AffDG: 去噪器引导 (式 11-12)	11
3.4 武器三 · AffLL: 显式密度模型 (式 31-32)	12
第 4 站 · § 4 实验设计: 三个问题、四组数据	12
第 5 站 · § 5 结果与讨论: 从数字到“蛇变水”	13
5.1 瑞士卷: 验证“确实最小化交叉熵” (Table 1)	13
5.2 仿射投影不损害性能 (Figure 2)	13
5.3 草地纹理: AffGAN 胜出, 两个“正统”方法出局 (Figure 3)	14
5.4 CelebA 人脸: 感知-失真权衡 (Figure 4 + Table 2)	14
5.5 ImageNet: 整体可信, 但会“梦见”不存在的东西 (Figure 5)	14
5.6 自我批评: MAP 的两个原则性问题	15
第 6 站 · § 6 结论: 一段话与三个定位	15
第 7 站 · 附录精读: 证明与细节的白话版	16
附录 A: 为什么“修正 GAN” = 最小化反向 KL (式 13-20)	16
附录 B: 伪逆的数值求解与梯度 (式 21-25)	16
附录 C: 实例噪声的病理学 (含 Figure 6)	17
附录 D/E: 训练细节与两个落败者的“尸检” (Figure 7)	17
附录 F: 随机版 AffGAN = 摊销变分推断 (式 36-47)	18
终点站 · 自测清单与配套材料索引	18
读完自测 (答不上就回到对应站)	18
论文章节 ↔ 配套材料对照	19

第 0 站 · 标题拆解与摘要精读

标题四个词，就是论文的全部承诺

🔍 **逐项拆解** ▶ **Amortised** (摊销的) —— 本意是会计术语“分期摊还”。机器学习里指：不再对每个输入单独跑一遍优化，而是把优化的成本一次性付在训练里，训练出一个函数，测试时前向一次直接给出（近似）最优解。▶ 幻灯片 10

MAP (Maximum a Posteriori, 最大后验) —— 在所有解释得通的解里，取后验概率 $p(y|x)$ 最大的那一个，即后验分布的**众数 (mode)**。与之相对：MSE 训练对应后验**均值**，MAE 对应**中位数**。▶ 幻灯片 6

Inference (推断) —— 这里指从观测 x 反推隐藏量 y 的过程。合起来，“摊销 MAP 推断” = 训练一个网络，一步输出 MAP 风格的解。

Image Super-Resolution (图像超分辨率, SR) —— 从低分辨率 (LR) 图像估计高分辨率 (HR) 图像。核心麻烦：这是个**欠定逆问题**，一个输入对应无穷多合法输出。

AffGAN 这个名字 = **Affine projection** (仿射投影) + **GAN**。论文三种方法统一以前缀命名：Aff- 表示带投影，Soft- 表示只用软约束；后缀 GAN / DG (Denoiser-Guided) / LL (Log-Likelihood) 表示用哪种武器逼近交叉熵。

摘要的信息结构

原文大意 (意译)

摘要五步走：① **问题**——SR 欠定，大量合理的 HR 图像都能解释同一张下采样图；② **现状批判**——主流方法用经验风险最小化+逐像素 MSE，输出模糊、过度平滑、不真实；③ **主张**——更可取的是 MAP 推断：偏好在图像先验下概率高、因而看起来可信的解；但直接做 MAP 很难，因为要从样本建出图像先验；④ **方案**——提出摊销 MAP 推断：先用一个新架构把网络输出投影到“有效 SR 解的仿射子空间”（保证输出与输入一致），再证明此时摊销 MAP 归约为最小化两个分布的交叉熵（类似训练生成模型），最后给出三种求解办法：GAN、去噪器引导、最大似然先验基线；⑤ **结论**——GAN 版本在真实图像上最好，纹理超分尤其出色。

💡 **人话直觉** ▶ 一句话浓缩：“多解问题别取平均，去爬概率峰顶；爬峰顶这件事，可以改写成生成式建模，然后交给 GAN。”

⚠ **易错点** ▶ 摘要没有告诉你的三件事，读完全文才会补齐：① 整套一致性保证建立在**无噪线性观测模型** $x = Ay$ 且 A 已知之上 (§ 3.1)；② GAN 实际最小化的并不是交叉熵本身，而是差一个熵项的 KL 散度 (§ 3.2)；③ 作者自己在 § 5.6 对“MAP 是否真是我们想要的”泼了冷水（高维下众数未必典型）。读摘要时留个心眼，别把方法边界读丢了。

第 1 站 · § 1 引言：为什么放弃 MSE、转向 MAP

📌 **本节脉络** ▶ 引言做三件事：①把 SR 定义成欠定逆问题，指出 MSE 的失败是**贝叶斯意义上注定的**，不是网络不够大；②交代“换感知损失”这条路为什么暂时走不通；③用一个二维玩具 (Figure 1) 把“MAP 优于均值/中位数”画给你看，并预告全文两大贡献。主线位置：第 ① 步“为什么要 MAP”。▶ 幻灯片 4 ▶ 幻灯片 5

▶ 幻灯片 6 ▶ 幻灯片 7 ▶ 幻灯片 8

1.1 欠定逆问题与“平均必糊”

原文大意（意译）

SR 的任务是给定 LR 输入估计 HR 图像。它欠定：以 $4\times$ 超分为例，输出像素数是输入的 16 倍，大量 HR 图像下采样后得到同一张 LR 图。主流方法做经验风险最小化（多用逐像素 MSE），而 MSE 这类凸损失面对多峰分布（比如自然图像分布）时有个已知缺陷：贝叶斯最优行为是输出所有合理解的后验加权平均。对自然图像来说，这种平均导致模糊、过度平滑、看起来不真实——即产出的估计在自然图像先验下概率很低。

■ 术语卡 ▶ 欠定 (underdetermined)：未知数多于约束，解不唯一。逆问题 (inverse problem)：由结果 (LR 图) 反推原因 (HR 图)。经验风险最小化 (ERM)：在训练对 (x, y) 上最小化平均损失 $\mathbb{E}[\ell(y, f_\theta(x))]$ ，即“有标准答案的监督回归”。

🔍 逐项拆解 ▶ “MSE 最优解 = 后验均值”是本文一切动机的地基，补上论文省略的一行证明：固定 x ，在所有可能输出 a 中最小化 $\mathbb{E}_{y|x} \|y - a\|_2^2$ ，对 a 求导置零得 $a^* = \mathbb{E}[y|x]$ ，即后验均值。同理可证 MAE 的最优解是后验中位数、0-1 损失（离散情形）的最优解是众数。所以：网络训练得再完美，MSE 也只会让它输出“平均图”——两种都合理的纹理逐像素平均后，高频细节相互抵消，只剩模糊底色。 ▶ 幻灯片 6

1.2 为什么不直接换“感知损失”

原文大意（意译）

理想方案是用一个全参考感知损失刻画人眼对失真的敏感度。但最常用的 MSE 及其亲戚 PSNR 与人的画质感知相关性差；改进指标 (SSIM、MS-SSIM 及后续工作) 虽有进步，仍不足以作为训练神经网络的满意替代。于是本文干脆离开经验风险最小化框架，只依赖自然图像统计来做文章。

💡 人话直觉 ▶ 这段话是全文的“岔路口”：别人修损失函数，本文换问题表述——不问“输出离标准答案多近”，改问“输出像不像一张真实图像、且是否与输入一致”。后面所有数学都是把这句话形式化。

1.3 Figure 1: 全文题眼，务必读透

原文大意（意译）

玩具设定：HR 数据是二维点 $y = [y_1, y_2]$ ，从瑞士卷分布中采样；下采样定义为两像素取平均 $x = (y_1 + y_2)/2$ 。观测到 $x = 0.5$ 时，所有合法解构成直线 $y_2 = 1 - y_1$ （更一般地：一个仿射子空间）。后验 $p(y|x)$ 因此退化为“先验沿这条线的切片”。最小化 MSE / MAE 的贝叶斯最优解分别落在这条线上的均值 / 中位数处——它们可能位于先验密度很低的地方；而 MAP 推断按定义找众数，必然落在高概率区。图 b 进一步把 x 从 -8 扫到 8 ，画出各训练模型的输出轨迹：AffGAN 与 AffDG 紧贴后验众数，MSE 与 MAE 的输出则频繁穿越低概率区域。

🔍 逐项拆解 ▶ 把这张图拆成四步读： ▶ 幻灯片 7

- ① 约束——下采样是线性算子： $x = Ay$ ，这里 $A = [1/2, 1/2]$ 是 1×2 矩阵。给定 x ，解集 $\{y : Ay = x\}$ 是一条直线（高维时是仿射子空间）。低清图给的不是答案，是一个约束。
- ② 后验——先验 p_Y （灰色瑞士卷，越深密度越高）沿约束线切一刀，得到红色阴影的一维后验。
- ③ 选点——同一条后验，三种损失给出三个不同的“最优点”：均值可能落在两卷之间的空地（两个峰平均出一个谁都不像的点）；中位数是折中；众数落在红色最深处。

④ 验证——图 b 中黑色小箭头是用去噪函数估计出的 $\nabla_y \log p_Y$ 梯度场（§ 3.3 的伏笔：箭头都指向瑞士卷高密度处）；彩色轨迹是各模型对不同 x 的输出。

⚠ 易错点 ▶ Figure 1 的两个经典读图错误：① 图中彩色点不是数据点，而是各方法的超分输出；② 图 a 和图 b 都有蓝色点，但含义不同——图 a 的蓝点是暴力求出的 MAP 解，图 b 的蓝点是训练出的 AffGAN 输出（红 = MSE，绿 = MAE，紫 = AffDG）。讲解时务必提醒听众。

■ 术语卡 ▶ 仿射子空间 (affine subspace)：线性子空间平移后的结果——过原点的叫线性子空间，不过原点的叫仿射子空间。解集 $\{y: Ay = x\}$ 当 $x \neq 0$ 时不过原点，故称“仿射”。这个词就是 AffGAN 里“Aff”的出处。

1.4 引言承诺的两大贡献

原文大意（意译）

贡献一：一种利用 SR 问题结构的 CNN 架构——下采样是线性变换（可建模为带步长的卷积），与任意 LR 图像相容的 HR 图像张成仿射子空间；用特定选择的线性卷积与反卷积层即可实现向该子空间的投影，从而保证网络输出恒与输入一致。该投影层可以加到任何 CNN、乃至任何可训练的 SR 算法上。贡献二：在此架构下，为 MAP 推断训练模型归约为最小化 HR 数据分布 p_Y 与模型输出分布 q_G 之间的交叉熵 $H[q_G, p_Y]$ ——于是不再需要成对的 HR-LR 数据，训练更像训练生成模型。据此给出三条逼近路线：GAN（并顺带提出稳定 GAN 训练的通用技巧“实例噪声”）、去噪器引导（贝叶斯最优去噪器近似给出对数密度梯度，可反传训练网络）、以及最大似然密度模型基线（PixelCNN + MCGSM）。

💡 人话直觉 ▶ 记住论文的“承诺清单”，后面每一节都是在兑现：投影层（§ 3.1）→ 交叉熵化归（§ 3.1 末）→ AffGAN+实例噪声（§ 3.2）→ AffDG（§ 3.3）→ AffLL（§ 3.4）→ 实验逐项验证（§ 5）。

第 2 站 · § 2 相关工作：本文站在哪三条线的交点上

📌 本节脉络 ▶ 相关工作按三条线读：① GAN 理论线——本文的修正更新规则在“GAN 到底在最小化什么散度”谱系中的位置；② GAN 做 SR 线——与 SRGAN 等工作的分工与区别；③ 去噪 = 梯度线——AffDG 的理论血统。▶ 幻灯片 16

原文大意（意译）

GAN 理论线：Goodfellow 等 (2014) 提出 GAN 框架，并证明在特定条件下其训练最小化 q_G 与 p_Y 间的 Jensen-Shannon 散度。本文 § 3.2 给出的更新规则对应最小化 $KL[q_G \parallel p_Y]$ （该结论最早见于 Huszár 2016 的一篇未发表笔记）。Nowozin 等 (2016) 的 f-GAN 把 GAN 推广到一般 f-散度极小化；与本文平行，Mohamed 与 Lakshminarayanan (2016) 给出隐式生成模型学习的统一视角，本文变体可视作其特例。近期多篇工作聚焦稳定 GAN 的算法技巧 (DCGAN、Salimans 等 2016)；本文 § 3.2.1 贡献另一个技巧——实例噪声，并与单边标签平滑对比；Arjovsky 与 Bottou (2017) 在平行工作中提出了类似方法。**GAN 做 SR 线：**Bruna 等 (2016) 与 Li & Wand (2016) 在预训练分类网络的特征空间里量距离；Dosovitskiy & Brox (2016) 与 Ledig 等 (2016, 即 SRGAN) 在类似思路上加对抗损失；Garcia (2016) 的未发表工作探索 GAN 加“LR 输入与下采样输出之间的 L1 惩罚”。本文指出：这些方法中的软 L2 / L1 惩罚可以解释为假设了高斯 / 拉普拉斯观测噪声；而本文假设无观测噪声，用仿射投影精确满足输入-输出一致性。另外 Larsen 等 (2015) 把 VAE 的逐像素 MSE 换成 GAN 判别器学到的度量。

去噪 = 梯度线: 概率建模与去噪学习之间有基本联系 (Vincent 等 2008; Vincent 2011; Särelä & Valpola 2005; Alain & Bengio 2014; Rasmus 等 2015): 贝叶斯最优去噪器可用来估计数据对数概率的梯度。据作者所知, 把去噪器的输出**显式反传去训练另一个网络**, 本文是第一次。

逐项拆解 ▶ “软惩罚 = 假设观测噪声”这句是相关工作里最有信息量的一句, 展开讲: 若假设 $x = Ay + \varepsilon$, ε 为高斯噪声, 则对数似然 $\log p(x|y) \propto -\|x - Ay\|_2^2 / (2\sigma^2)$ ——正是 L2 软惩罚项; 换拉普拉斯噪声就得到 L1 (即 Garcia 用的 MAE 项)。反过来读: **你在损失里加的每个软约束, 都对应一个隐含的噪声假设**。本文说“我假设无噪声”, 于是软惩罚升级为硬投影, 一致性从“被鼓励”变成“被保证”。▶ 幻灯片 16

易错点 ▶ 与 SRGAN 的关系别说成“打败了 SRGAN”: 论文没有与 SRGAN 做直接数值对比, 两者是互补关系——SRGAN 是“对抗+感知损失”的工程组合、依赖成对数据; 本文为“在 SR 里用生成式目标”补充了理论动机 (摊销 MAP), 并把一致性从内容损失的副产品变成结构保证。论文自己的措辞是: 我们的分析为在图像 SR 中使用 GAN (Ledig 等 2016) 提供了理论依据。

延伸 ▶ 时间线冷知识: 单边标签平滑 (Salimans 等) 与本文同为 2016 年工作, “实例噪声 vs 标签平滑”是同期两种药方之争; Arjovsky & Bottou (2017) 沿同一病因分析走向了 Wasserstein GAN 的前奏。去噪线的思想后来在 score matching / 扩散模型中大放异彩——见 § 3.3 的延伸框。

第 3 站 · § 3 理论: 从 MAP 到交叉熵的完整推导

本节脉络 ▶ 这是全文最硬、也最值得逐行读的一章, 占理解难度的七成。路线图: 先把“摊销 MAP”写成一个优化目标 (式 1-4), 再用观测模型把似然项变成硬约束 (式 5-6), 用仿射投影把硬约束吃进网络结构 (式 7), 最后发现剩下的目标恰好是交叉熵 (式 8-9)——至此“超分”正式变成“生成式建模”。随后三小节给出三件武器。▶ 幻灯片 10 ▶ 幻灯片 11 ▶ 幻灯片 12 ▶ 幻灯片 13

3.0 从经验风险到摊销 MAP (式 1-4)

原文大意 (意译)

设 $f_\theta(x)$ 是把 LR 观测 x 映到 HR 估计 $\hat{y}$ 的参数化函数。多数现有方法通过经验风险最小化学习参数:

$$\arg \min_{\theta} \mathbb{E}_{y,x} [\ell(y, f_\theta(x))] \quad (\text{论文式 1})$$

原文大意 (意译)

其中 ℓ 通常取 MSE。本文改做 MAP 推断。对单个观测 x , MAP 估计为:

$$\hat{y}(x) = \arg \max_y \log p_{Y|X}(y|x) \quad (\text{论文式 2})$$

原文大意 (意译)

与其对每个 x 单独求解式 (2), 本文做**摊销推断**: 训练 f_θ 直接输出 MAP 估计。自然的训练目标是平均对数后验:

$$\arg \max_{\theta} \mathbb{E}_x \log p_{Y|X}(f_\theta(x)|x) \quad (\text{论文式 3})$$

原文大意（意译）

期望取在 LR 观测的分布上。该目标依赖未知的后验 $p_{Y|X}$ ，于是用贝叶斯公式把对数后验分解为三项：

$$\arg \max_{\theta} \left\{ \underbrace{\mathbb{E}_x \log p_{X|Y}(x|f_{\theta}(x))}_{\text{似然}} + \underbrace{\mathbb{E}_x \log p_Y(f_{\theta}(x))}_{\text{先验}} - \underbrace{\mathbb{E}_x \log p_X(x)}_{\text{边缘似然}} \right\} \quad (\text{论文式 4})$$

🔍 逐项拆解 ▶ 三个式子的递进关系值得慢读：式 (2) 是“每张图跑一遍优化”（慢、非凸、每次都重来）；式 (3) 把 $\arg \max$ 从“对 y ”换成“对 θ ”——**优化对象从解本身变成产生解的函数**，这就是摊销。式 (4) 三项各管一摊：**似然项**管“输出跟输入对不对得上”（数据一致性）；**先验项**管“输出像不像一张真实图像”（自然性）；**边缘似然项** $\log p_X(x)$ 与 θ 完全无关，直接扔掉。剩下的两项，恰好对应后面两大发明：似然项 → 仿射投影 (§ 3.1)，先验项 → 交叉熵与三种武器 (§ 3.1 末–§ 3.4)。▶ 幻灯片 10

💡 人话直觉 ▶ 摊销 = “把逐张优化的钱，一次付在训练里”。训练贵一点，换来测试时前向一次出图。

⚠️ 易错点 ▶ 式 (3) 不是一个新损失函数替换 MSE 那么简单：它的期望**只对 x 取**，公式里根本没有成对的真值 y 出现——这个细节预告了后面“不需要配对数据”的结论。对照式 (1) 里 $\mathbb{E}_{y,x}$ 的双下标，差别一目了然。

3.1 处理似然项：仿射投影层（式 5–7）

原文大意（意译）

SR 的观测模型写作

$$x = A\hat{y} \quad (\text{论文式 5})$$

原文大意（意译）

其中 A 是用于下采样的线性变换，一般可建模为带步长的二维卷积。因此式 (4) 中的似然项是退化的： $p(x|f_{\theta}(x)) = \delta(x - Af_{\theta}(x))$ ，式 (4) 变成约束优化：

$$\arg \max_{\theta, \forall x: Af_{\theta}(x)=x} \mathbb{E}_x[\log p_Y(f_{\theta}(x))] \quad (\text{论文式 6})$$

原文大意（意译）

为满足约束，引入一族天生满足 $Af_{\theta}(x) = x$ 的函数：

$$g_{\theta}(x) = \Pi_x^A f_{\theta}(x) = (I - A^+A)f_{\theta}(x) + A^+x \quad (\text{论文式 7})$$

原文大意（意译）

其中 f_{θ} 是任意 LR→HR 映射， Π_x^A 是向仿射子空间 $\{y : Ay = x\}$ 的投影， A^+ 是 A 的 Moore–Penrose 伪逆（满足 $AA^+A = A$ 与 $A^+AA^+ = A^+$ ）。若 A 是带步长的卷积， A^+ 就是一次反卷积/上卷积——深度学习标准操作；但**最优的 A^+ 并不是 A 的转置**，本文用数值方法求解（附录 B）。直觉上， A^+x 可视为一个基线 SR 解， $(I - A^+A)f_{\theta}$ 是残差；算子 $(I - A^+A)$ 恰是向 A 的零空间的投影，所以无论 f_{θ} 输出什么，残差下采样后必为 0。

■ 术语卡 ▶ δ 分布 (Dirac delta)：把全部概率压在一个点上的“极限分布”。“似是 δ ”意味着：观测无噪声， y 要么精确解释 x （下采样后相等），要么概率为零——没有中间地带。**零空间 (null space)**：被 A

映成 0 的向量集合 $\{v: Av = 0\}$; 沿零空间方向移动, 下采样结果不变。**Moore–Penrose 伪逆**: 不可逆 (非方阵) 矩阵的“最稳反操作”, 此处只用到 $AA^+A = A$ 这一条性质。▶ 幻灯片 11

🔍 **逐项拆解** ▶ 式 (7) 是全文最硬核的一行, 逐块拆:

块① A^+x (基线解) —— 把 LR 图直接“抬”回 HR 空间的一个特解。验证它合法: $A(A^+x) = AA^+Ay = Ay = x$ (第二个等号用了 $x = Ay$ 与 $AA^+A = A$)。它保证低频内容正确, 但没有高频细节。

块② $(I - A^+A)f_\theta(x)$ (零空间残差) —— 网络的全部自由度。验证它“下采样后隐形”: $A(I - A^+A)f_\theta = (A - AA^+A)f_\theta = (A - A)f_\theta = 0$ 。

合起来: $A g_\theta(x) = 0 + x = x$, 一致性对任意 θ 、任意输入恒成立——是结构强制的, 不是损失鼓励的。几何图景: 整个仿射子空间是一张“合法解平面”, A^+x 是平面上的锚点, 网络输出被投影回平面上离它最近的点 (用 Moore–Penrose 伪逆时该投影恰为正交投影)。▶ 幻灯片 12

💡 **人话直觉** ▶ 一句话: 底图管对得上, 残差管好不好看; 残差被锁在“下采样隐形”的方向里, 怎么折腾都不会破坏一致性。

⚠️ **易错点** ▶ 三个高频口误: ① $A^+ \neq A^\top$ —— 伪逆的卷积核要数值求解 (附录 B), Figure 2d 可视化了两者: A 是固定的高斯核, A^+ 却带负瓣, 长得像锐化核; ② A 从头到尾是固定的 (9×9 高斯核、步长 4), 被学习/优化的只有 A^+ 的初始化 (且训练中冻结或微调均可, 见 § 5.2); ③ 这一切成立的前提是无噪线性观测模型且 A 已知——被问“真实退化未知怎么办”时, 答案是“超出本文设定, 软约束版可作退路但效果更差”。

3.1 续: 化归交叉熵 (式 8–9) —— 全文最漂亮的一步

原文大意 (意译)

用式 (7) 的函数族后, 式 (6) 变成无约束优化:

$$\arg \max_{\theta} \mathbb{E}_x \log p_Y(\Pi_x^A f_\theta(x)) \quad (\text{论文式 8})$$

原文大意 (意译)

有趣的是, 这个目标可以用“模型输出的概率分布” $q_\theta(y) := \int \delta(y - \Pi_x^A f_\theta(x)) p_X(x) dx$ 改写为:

$$\arg \max_{\theta} \mathbb{E}_x \log p_Y(\Pi_x^A f_\theta(x)) = \arg \max_{\theta} \mathbb{E}_{\hat{y} \sim q_\theta} \log p_Y(\hat{y}) = \arg \min_{\theta} H[q_\theta, p_Y] \quad (\text{论文式 9})$$

原文大意 (意译)

其中 $H[q, p]$ 是交叉熵, 且 $H[q_\theta, p_Y] = \mathbb{E}_{\hat{y} \sim q_\theta} [-\log p_Y(\hat{y})]$ 。最小化这个目标不需要匹配的输入–输出对, 只需让“重建图像的边缘分布 q_θ ”匹配“HR 图像分布 p_Y ”——问题从此更像无监督学习或生成式建模。

🔍 **逐项拆解** ▶ q_θ 的定义式看着吓人, 其实是句大白话: 把所有低清图 (按 p_X 的出现频率) 过一遍网络, 收集全部输出, 这些输出构成的分布就是 q_θ 。式 (9) 的等号也只是“换个记账方式”: 对 x 取期望再算 $\log p_Y$ (输出), 等于直接对“输出”取期望算 $\log p_Y$ ——因为输出由 x 唯一决定 (网络是确定性函数)。最后一个等号是交叉熵的定义。三个等号没有任何近似, 严格成立。▶ 幻灯片 13

💡 **人话直觉** ▶ 翻译成人话: “让每张输出图在真实图像先验下尽量高概率” = “让输出人群整体搬进真实图像的高密度社区”。从此训练只需要三样东西: 一堆低清图 (不需要对应答案)、一堆高清图 (不需要对应输入)、已知的 A 。

⚠ **易错点** ▶ 两个细节别读过头：① 交叉熵低 $\neq$ 两分布匹配—— $H[q, p] = H[q] + \text{KL}[q \parallel p]$ ，它还含 q 自身的熵，最小化交叉熵会**额外**偏好低熵（塌向众数）的解，这正是“MAP 味”的来源，也是下一节 GAN 替代目标“差一个熵项”讨论的伏笔；② 式 (9) 仍然**没法直接算**—— p_Y 是未知的自然图像分布，这就是需要三种武器的原因。

3.2 武器一 · AffGAN：仿射投影 + 修正更新规则（式 10）

原文大意（意译）

GAN 由生成器 G （把噪声 $z \sim p_Z$ 映成图像）与判别器 D （区分真假图像）组成，两者交替更新，使生成分布 q_G 逼近真实分布 p_Y 。GAN 的行为取决于训练细节，本文采用如下目标：

$$\mathcal{L}(D; G) = -\mathbb{E}_{y \sim p_Y} \log D(y) - \mathbb{E}_{z \sim p_Z} \log(1 - D(G(z))), \quad \mathcal{L}(G; D) = -\mathbb{E}_{z \sim p_Z} \log \frac{D(G(z))}{1 - D(G(z))} \quad (\text{论文式 10})$$

原文大意（意译）

算法交替两步：固定 G 降低 $\mathcal{L}(D; G)$ ，再固定 D 降低 $\mathcal{L}(G; D)$ 。可以证明这相当于最小化 $\text{KL}[q_G \parallel p_Y]$ （证明见附录 A，结论最早由 Huszár 2016 给出）。在 SR 语境下，**带仿射投影的 SR 函数 $\Pi_x^A f_\theta$ 充当生成器**，输入不再是噪声而是低清图 $x \sim p_X$ ，其余保持不变，即可用 GAN 算法最小化 $\text{KL}[q_\theta \parallel p_Y]$ ——此法名为 AffGAN。对照组 SoftGAN 去掉投影，改用软约束 $\ell_{\text{LR}} = \text{MAE}(x, A\hat{y})$ 。注意交叉熵与 KL 之差恰为 q_θ 的熵： $H[q_\theta, p_Y] - \text{KL}[q_\theta \parallel p_Y] = H[q_\theta]$ ，因此可以预期 AffGAN 偏好熵更高、整体上更多样的近似 MAP 解。

🔍 **逐项拆解** ▶ 式 (10) 两行分工明确：第一行是**判别器损失**——标准二分类交叉熵（真图打 1、假图打 0），没有任何改动。第二行是**生成器损失**，这才是修改所在：原版 GAN 生成器最小化 $\log(1 - D)$ （或实践中最大化 $\log D$ ），本文让生成器最小化 $-\log \frac{D}{1-D}$ ——把两者**合并成对数几率（logit）**。差别的后果：原版 minimax 在最优判别器下对应最小化 JS 散度，修正版恰好对应最小化**反向 KL** $\text{KL}[q_\theta \parallel p_Y]$ （推导见附录 A 精读）。而反向 KL 与我们真正想要的交叉熵只差一个熵项——这是“用 GAN 逼近 MAP”在数学上成立的关键一环。

▶ 幻灯片 15 ▶ 幻灯片 17

💡 **人话直觉** ▶ 熵差那行公式值得单独记：**想要的（交叉熵）- 实际最小化的（KL）= 熵奖励 $H[q_\theta]$** 。纯交叉熵会把一切压向众数；KL 版本额外奖励输出分布的多样性。论文原话到“偏好更高熵、更多样的解”为止；“因此有助于缓解 mode collapse”是顺理成章的引申，但**论文没有直接这么说**，讲的时候注意区分。▶ 幻灯片 18

⚠ **易错点** ▶ “多样性”指的是**边缘输出分布 q_θ 跨不同输入的多样性**：这个模型是确定性的，同一张 x 永远只输出同一张图。想要“同一输入多个解”，要等附录 F 的随机版扩展。

3.2.1 实例噪声：GAN 为什么不稳、怎么救（式 26）

原文大意（意译）

理论上 GAN 应当收敛：若最优判别器唯一且每步都训到最优，整个算法就是对 $\text{KL}[q_\theta \parallel p_Y]$ 估计值的梯度下降。实践中 GAN 却出名地不稳。哪里出了问题？作者认为主因是 q_θ 与 p_Y 都是**集中**的分布，支撑几乎不重叠：自然图像分布通常被认为集中在低维流形附近，而 q_θ （如 AffGAN 中）按构造就是退化、类流形的。于是尤其在收敛前，存在一大批都能完美区分两者的判别器，破坏了收敛性证明的前提。解决办法：给 SR 输出和真实图像**同时加噪声**（实例噪声），等价于最小化

$$d_\sigma(q_\theta, p_Y) = \text{KL}[p_\sigma * q_\theta \parallel p_\sigma * p_Y] \quad (\text{论文式 26})$$

原文大意（意译）

其中 $p_\sigma * q$ 表示分布与噪声分布的卷积。噪声强度 σ 随训练退火；加噪后可以放心把 D 训到收敛。该技巧与 Salimans 等（2016）的单边标签平滑相关，但不会给最优判别器引入偏差，作者认为它是稳定 GAN 训练的通用候选。细节见附录 C。

逐项拆解 ▶ 病根拆成三条（附录 C 展开，这里先给结论）：支撑不重叠时，① 对数似然比 $\log q_\theta/p_Y$ 处处无穷 → KL 失去定义；② JS 散度饱和在最大值、对 θ 局部恒定 → 没有梯度；③ 逻辑回归损失接近最优的判别器有一大堆，每个给生成器的梯度方向各不相同 → 训练随初始化漂移。实例噪声一招治三症：卷积把两个“细线”分布抹宽，支撑重叠 → 似然比有限、JS 不再饱和、最优判别器唯一。 σ 退火到 0 时回到原问题。▶ 幻灯片 19

人话直觉 ▶ 比喻：两条几乎不相交的细线，有无数种画法能把它们分开；给两条线都“吹一层气”变成两团重叠的雾，分界线就只剩一条了。

延伸 ▶ 这一小节是本文影响力最大的副产品：与 Arjovsky & Bottou（2017）的平行分析共同构成了后来 WGAN 系列的病因诊断；“对样本加噪并退火”的做法与扩散模型的噪声调度直觉相通——但目的不同：实例噪声是为了稳定判别器，扩散模型的加噪定义了生成过程本身。同源不同用。

3.3 武器二 · AffDG：去噪器引导（式 11-12）

原文大意（意译）

要用梯度下降优化式 (6)，需要目标对 θ 的梯度：

$$\frac{\partial}{\partial \theta} \mathbb{E}_x [\log p(\Pi_x^A f_\theta(x))] = \mathbb{E}_x \left[\underbrace{\nabla_y \log p(y) |_{y=\Pi_x^A f_\theta(x)}}_{\text{得分项 (score)}} \cdot \underbrace{\Pi_x^A \frac{\partial}{\partial \theta} f_\theta(x)}_{\text{网络梯度经投影}} \right] \quad (\text{论文式 11})$$

原文大意（意译）

网络梯度可反向传播求得，但得分项 $\nabla_y \log p_Y(y)$ 依赖未知的 p_Y ，需要估计。借用 Alain & Bengio (2014) 等的结论：在无穷小高斯噪声极限下，最优去噪函数可用于估计该梯度——

$$f_\sigma^* = \arg \min_f \mathbb{E}_{y \sim p_Y} \ell_{\text{MSE}}(f(y + \sigma \varepsilon), y) \Rightarrow \frac{f^*(y) - y}{\sigma^2} \approx \nabla_y \log p_Y(y) \quad (\text{论文式 12})$$

原文大意（意译）

其中 $\varepsilon \sim N(0, I)$ 为高斯白噪声。于是流程是：先训练一个神经网络对来自 p_Y 的样本去噪，再把式 (12) 的梯度估计经式 (11) 的链式法则反传，更新 θ 。方法命名 AffDG（仿射投影 + Denoiser-Guided）；软约束对照组称 SoftDG。

逐项拆解 ▶ 式 (12) 的直觉推导（论文引用文献，这里补一版直觉）：给真图 y 加噪得 $\tilde{y}$ ，最优去噪器输出的是“看到 $\tilde{y}$ 时干净图的后验均值”。噪声很小时，这个后验均值相对 $\tilde{y}$ 的偏移方向，恰好指向“附近密度更高的地方”——因为噪声把点均匀地推离原位，而“拉回去”的最优方向就是密度上升最快的方向。于是 **去噪残差** $\div \sigma^2 \approx$ **对数密度梯度 (score)**。适用条件别丢：**小噪声极限下的近似**，所以训练要做 σ 退火。▶ 幻灯片 20

▶ 幻灯片 21

训练两阶段（附录 D 式 27-30）：**阶段一**预训练去噪自编码器（DAE），期间退火 σ 并保存各噪声水平下的参数快照；**阶段二**训练 SR 网络——输出 $\hat{y}$ 喂给 DAE 拿梯度估计、按链式法则反传做梯度上升；期间 DAE 不

被 SR 损失更新，但会按退火计划换用更低噪声水平的参数快照：大噪声版本梯度粗但覆盖广（训练早期用），小噪声版本梯度准但只在流形附近有效（后期用）。

💡 **人话直觉** ▶ 一句话：不用写出先验密度，训练一个去噪器就等于拿到了“往更像真图的方向走”的指南针。论文自述这是首次把去噪器输出显式反传去训练另一个网络。

🔗 **延伸** ▶ 这条线是今天 score-based / 扩散模型的直系祖先之一（Vincent 2011 的 denoising score matching → 本文的去噪引导 → Song & Ermon 2019 的 NCSN → DDPM）。回答“和扩散模型什么关系”时的标准句式：思想同源（去噪 ≈ 估计 score），流程不同（这里是用冻结去噪器引导前馈网络，不是多步加噪-去噪的生成链）。

3.4 武器三 · AffLL：显式密度模型（式 31–32）

原文大意（意译）

最直接的基线：用最大似然拟合一个“可处理但强大”的密度模型逼近 p_Y ，再用生成样本在该模型下的交叉熵近似式 (9)。具体用类 PixelCNN 的结构（Oord 等 2016），但把似然换成连续且可微的 MCGSM（条件高斯尺度混合的混合，Theis 等 2012）。命名 AffLL（仿射投影 + Log-Likelihood 引导）。训练分两步：先按链式分解 $L(y) = \sum_j \log p(y_j | y_{<j})$ 最大化密度模型的对数似然（式 31），再最小化生成样本的负对数似然 $\ell = -L(f_\theta(x))$ （式 32）来训练 SR 网络。

🔍 **逐项拆解** ▶ 为什么非换 MCGSM 不可：原版 PixelCNN 把每个像素建成 256 类的离散分类分布——对输入图像不可导，没法把“先验打分”的梯度传回 SR 网络。MCGSM 是连续可微的密度，才能当“可反传的打分器”。▶ 幻灯片 22

💡 **人话直觉** ▶ 三种武器一句话对比：AffGAN 让判别器当裁判（隐式、对抗式）；AffDG 让去噪器当指南针（只给梯度方向）；AffLL 让密度模型当打分器（显式打分）。理论上越靠后越“正统”，实验里却越靠前越能打——原因在 § 5.3 与附录 E。

第 4 站 · § 4 实验设计：三个问题、四组数据

📌 **本节脉络** ▶ 实验章很短，但设计意图值得先看清：作者把整个实验组织成对三个问题的回答，难度从二维玩具一路爬到真实自然图像。▶ 幻灯片 23

原文大意（意译）

实验回答三个问题：① § 3 的方法真的在最小化交叉熵吗？→ § 5.1；② 仿射投影层会不会损害 CNN 的超分性能？→ § 5.2；③ 这些方法能产出感知上更好的超分结果吗？→ § 5.3–5.5。先在“可以暴力算出精确 MAP”的二维瑞士卷上验证理论，再在真实图像上做 4× 超分：草地纹理（对 MSE/MAE 出名地难）、CelebA 人脸、ImageNet 自然图像。全部模型是卷积网络，用 Theano + Lasagne 实现。

🔍 **逐项拆解** ▶ 实验设置速查（汇总自 § 4 与附录 D，讲稿被追问时用）：

实验	数据与退化	模型要点
瑞士卷	二维点 $y = [\cos(\nu_1)r, \sin(\nu_1)r]$, $r = 0.4\nu_1 + \nu_2$, $\nu_1 \sim N(10, 3)$, $\nu_2 \sim N(0, 0.2)$; $x = (y_1 + y_2)/2$	生成器/判别器均为 2 层 64 单元全连接网络; DAE 为 2 层 256 单元, 噪声从 0.5 退火到 0.25
草地纹理	高分辨率草地图随机裁剪, $4\times$	生成器 6 层卷积 (32→128 滤波器, 隔层跳连); 判别器 4 层步长卷积
CelebA	中心裁剪缩放到 64×64 , 再用 A 降到 16×16	生成器 12 层卷积、判别器 8 层; 标准训练/验证/测试划分
ImageNet	中心裁剪缩放到 128×128 , 降到 32×32 ; 剔除小于 20kB 的图	生成器 8 层、判别器 8 层; 必须 加实例噪声 (σ 从 0.1 线性退火到 0) 才能稳定训练

所有图像实验共用的观测模型: A = 固定的 9×9 高斯平滑核、步长 4 的卷积 (即 $4\times$ 下采样); A^+ = “16 个 5×5 卷积核 + 亚像素重排” (Shi 等 2016 的 sub-pixel 卷积), 核参数按附录 B 数值优化。所有下采样都用这个 A 完成。生成器带 ReLU、批归一化与跳连, 输出接 sigmoid 后进投影层。

△ 易错点 ▶ “ImageNet 上不加实例噪声就训不动” 这句出现在附录 D 里, 很容易漏读——它是实例噪声价值最硬的实验证据, 讲稿里值得点一句。

第 5 站 · § 5 结果与讨论：从数字到“蛇变水”

■ 5.1 瑞士卷：验证“确实在最小化交叉熵” (Table 1)

原文大意 (意译)

二维问题里 p_Y 可以用暴力蒙特卡洛评估 (对 5 万个无噪瑞士卷样本做核密度估计, 带宽 0.2), 于是交叉熵 $H[q_\theta, p_Y]$ 可以直接算出来当标尺。结果 (10 次随机初始化平均): AffGAN 与 AffDG 的输出轨迹基本贴住后验众数 (Figure 1b), 交叉熵接近暴力 MAP 解; MSE 与 MAE 显著更差——因为它们本来就不在最小化这个量。带投影的模型“输入 vs 下采样输出”的误差精确为 0, 软约束模型训练再久也只能近似满足; 且 Aff 系的交叉熵普遍低于对应的 Soft 系。

🔍 逐项拆解 ▶ Table 1 数字逐行读 (交叉熵越低越好): MAP 暴力解 3.15 是天花板; AffDG 3.81、AffGAN 4.10 贴近天花板; SoftDG 4.19、SoftGAN 4.25 次之——投影稳定优于软约束; MAE 6.30、MSE 9.10 远远跑偏。第二列一致性误差: Aff 系精确 0.0, Soft 系在 10^{-2} 到 10^{-1} 量级。两列合起来支撑两个结论: GAN/去噪引导确实在最小化目标交叉熵; 硬投影全面优于软约束。▶ 幻灯片 24

△ 易错点 ▶ 有趣的细节: 二维玩具里 AffDG (3.81) 比 AffGAN (4.10) 还好——去噪引导在低维时非常能打; 它输给 GAN 是**高维**的事 (§ 5.3), 原因见附录 E。别把“AffGAN 最佳”说成放之四海皆准。

■ 5.2 仿射投影不损害性能 (Figure 2)

原文大意 (意译)

加投影等于限制函数类, 需要验证不掉点。做法: 在 CelebA 上用 MSE 目标训练带/不带投影的同架构 CNN。发现: 带投影的网络随机初始化时起步损失就更低 (低频分量天生对齐目标), 训练普遍更快, 最

终 MSE/SSIM 往往更好。为定位收益来源又做两个变体：把 A^+ 初始化成正确伪逆后设为可训练；以及随机初始化最后的反卷积层再训练。结论：**把 A^+ 初始化成正确的 Moore–Penrose 伪逆很关键；初始化正确后，冻结还是继续训练差别不大。**精确投影的网络把“输入 vs 下采样输出”误差压在数值精度附近 (Figure 2c)，任何其他变体都会破坏一致性。Figure 2d 可视化了 A (上) 与数值求得的 A^+ (下)。

逐项拆解 ▶ Figure 2 图例的二元组 (·, ·) 要会读：第一位 F/T = 投影层固定 (Fixed) 还是可训练 (Trainable)；第二位 T/R = 初始化用训练好的伪逆 (Trained) 还是随机 (Random)。四条曲线里 (F,T) 与 (T,T) 几乎重合且最好，(T,R) 与无投影最差——正是“初始化关键、冻不冻随意”的图形证据。▶ 幻灯片 25

人话直觉 ▶ 这一节回答的是审稿人必问的“你的约束会不会伤性能”：不仅不伤，还因为“低频不用学了”而训得更快。附赠一个观察： A^+ 核长着负瓣（类似锐化核），直观解释了为什么它不是 A 的转置。

5.3 草地纹理：AffGAN 胜出，两个“正统”方法出局 (Figure 3)

原文大意 (意译)

随机纹理用 MSE 损失出名地难。4× 草地实验中：未训练的投影模型 (Aff_{init}，即纯 A^+x 基线) 已给出低频正确的输出；AffGAN 的结果明显最锐利，且作者认为在给定 LR 输入下是可信的——重建不是逐像素还原，但**统计性质正确**，人眼一看就认得是草。AffDG 与 AffLL 的结果都很模糊，换了多种优化手段也救不回来；据此作者停止这两个模型的后续实验，集中火力做 AffGAN (讨论移入附录 E)。

人话直觉 ▶ “统计性质正确、逐像素不同”是 GAN 系超分的精髓：纹理类内容本来就没有“唯一正确答案”，评价标准应该是“分布对不对”而不是“每个像素对不对”。这句话也是理解 § 5.4 感知-失真权衡的钥匙。▶ 幻灯片 26

5.4 CelebA 人脸：感知-失真权衡 (Figure 4 + Table 2)

原文大意 (意译)

不同损失训练的同架构模型对比：MSE 系输出平滑发糊但“安全”；AffGAN 与 SoftGAN 都明显更锐利，其中 AffGAN 略锐于 SoftGAN、但高频噪点也略多；软约束模型还出现颜色漂移。定量上 (Table 2)：按 PSNR / SSIM，MSE 系最高——AffMSE 达 SSIM 0.91 / PSNR 26.53，为全表之冠；AffGAN 为 0.81 / 23.02，高于 SoftGAN 的 0.76 / 21.11。一致性一列：AffMSE 1.6×10^{-10} 、AffGAN 9.1×10^{-10} ，比 Soft 系 (10^{-3} 到 10^{-5} 量级) 好出多个数量级。

逐项拆解 ▶ 读这张表的正确姿势：**两套指标在打架**——失真指标 (PSNR/SSIM，衡量逐像素/结构接近度) 说 MSE 系赢，视觉锐利度说 GAN 系赢。这不是矛盾，而是后来被 Blau & Michaeli (2018) 形式化的“感知-失真权衡”的一个早期实例：把多解平均能刷高 PSNR，却必然牺牲锐度。▶ 幻灯片 27

易错点 ▶ 措辞红线：本文没有做人类偏好评测。所以“AffGAN 更好看”的严谨说法是“视觉上更锐利、纹理更丰富，但 PSNR/SSIM 更低；两类指标衡量的东西不同”。把 PSNR 低说成“输了”或把锐利说成“人类验证更好”都是过度解读。

5.5 ImageNet：整体可信，但会“梦见”不存在的东西 (Figure 5)

原文大意 (意译)

用 AffGAN 在 ImageNet 上做 $32 \times 32 \rightarrow 128 \times 128$ 的 $4 \times$ 超分：多数结果锐利、与 LR 输入对应良好，但仍带有 GAN 常见的高频噪声，与真图可以区分。最有趣的失败案例：第三列的蛇被超分成了水——显然错误，但考虑到 LR 输入，这仍是一张非常可信的图像；而且水纹在图像先验下的密度很可能高于蛇皮，这说明 GAN 模型“梦出”的是合理的数据。

💡 **人话直觉** ▶ “蛇变水”是全文最好的一页 PPT 素材：它同时展示了方法的能力（生成先验下高概率的内容）与风险（高概率 $\neq$ 真实发生）。MAP 类方法追求“可信”，不承诺“还原”——医疗、取证等场景要格外小心这一点。▶ 幻灯片 28

5.6 自我批评：MAP 的两个原则性问题

原文大意（意译）

问题一：众数依赖表示。对随机变量做可逆变换后再做 MAP，答案可能随变换而变。极端例子：把连续标量 Y 用它自己的累积分布函数 F 变换，得到的 $F(Y)$ 服从均匀分布——均匀分布里每个点都是众数。因此“MAP 估计”在允许换表示时不唯一，本文在 24 位 RGB 像素表示下求的众数并无特殊地位；换成 CNN 特征空间、甚至只是换个色彩空间，都可能得到不同的解。有趣的是 AffGAN 对坐标变换更有韧性：其目标里多出的 $H[q_\theta]$ 项与 $H[q_\theta, p_Y]$ 受变换的影响方式相同。

问题二：众数未必典型。众数按定义在高概率区，但不保证长得像随机样本。例： d 维标准高斯，由测度集中，典型样本的范数以极高概率约为 $\sqrt{d}$ ，而众数（原点）范数为 0——在这个意义上众数高度非典型。人类观察者能轻易分辨“众数”与“典型样本”，却难以分辨两个随机样本。这提示：从后验 $p_{Y|X}$ 采样可能是获得可信重建的更好方式。给生成器额外喂噪声即可把 AffGAN 扩展成近似贝叶斯推断（类似 Denton 等 2015），附录 F 证明这个随机版可视为摊销变分推断（如 VAE, Kingma & Welling 2014）。

🔍 **逐项拆解** ▶ 两个论证各补一步直觉：

CDF 例子——概率密度在可逆变换下要乘雅可比 $|F'|^{-1}$ ，密度的“峰”会被拉平或搬家，所以“密度最高点”不是变换不变量。这不是技术瑕疵，是“用密度峰值定义最优解”这一思路的固有属性。

肥皂泡——高维球壳的体积随半径暴涨 ($\propto r^{d-1}$)，密度虽在 origin 最高，但“密度 $\times$ 体积”的质量几乎全部集中在半径 $\approx \sqrt{d}$ 的薄壳上。类比：氢原子电子密度在核处最大，但你几乎不可能在核上找到电子。这个比喻出自作者 Huszár 的博客（“高维高斯是肥皂泡”）。▶ 幻灯片 30

⚠ **易错点** ▶ 这节是作者主动写的“反方论证”，讲的时候千万别跳过——它不但诚实，还为附录 F 与整个“从后验采样”的后续研究方向（也回连到 PRSR 这类自回归采样方法）做了铺垫。跳过它，结尾的变分推断就成了无源之水。

第 6 站 · §6 结论：一段话与三个定位

原文大意（意译）

本文为 SR 的近似 MAP 推断开发了方法：先以架构限制把网络输出投影到有效解的仿射子空间，再给出 GAN、去噪、密度模型三种摊销 MAP 推断方案。高维实验表明 GAN 版本（AffGAN）视觉效果最佳。本工作接续了 GAN 系算法在图像 SR 上的成功实践（Ledig 等 2016），并补充了“为什么该这么做”的理论动机。未来工作聚焦 AffGAN 的随机扩展——可视作摊销变分推断。

💡 **人话直觉** ▶ 给论文历史定位的三句话（答辩/讨论可用）：① 它是“GAN 做超分”从工程直觉走向概率解释的关键一步；② 它的实例噪声与“支撑不重叠”诊断成为后续 GAN 稳定性研究（WGAN 一脉）的常引先声；③ 它的去噪引导思想与后来的 score-based / 扩散模型同源。 ▶ 幻灯片 33

第 7 站 · 附录精读：证明与细节的白话版

📌 **本节脉络** ▶ 六个附录做四件事：A 补 GAN=KL 的证明；B 补伪逆怎么算；C 展开实例噪声的病理解析；D/E 补实验细节与两个落败方法的尸检；F 给出通往变分推断的扩展。按重要性排序：A ≈ F > C > E > B > D。

附录 A：为什么“修正 GAN” = 最小化反向 KL（式 13-20）

原文大意（意译）

第一步：最优判别器长什么样。 固定生成器 G ，判别器最大化 $\mathbb{E}_{y \sim p_Y} \log D(y) + \mathbb{E}_{y \sim q_G} \log(1 - D(y))$ 。逐点看这是 $a \log t + b \log(1 - t)$ 型函数（ $a = p_Y(y)$, $b = q_G(y)$ ），最大值在 $t = a/(a + b)$ ，故（假设两类先验概率相等）：

$$D^*(y) = \frac{p_Y(y)}{p_Y(y) + q_G(y)} \quad (\text{论文式 16})$$

原文大意（意译）

第二步：代入生成器目标。 从 KL 的定义出发：

$$\text{KL}[q_G \parallel p_Y] = \mathbb{E}_{y \sim q_G} \log \frac{q_G(y)}{p_Y(y)} = \mathbb{E}_{y \sim q_G} \log \frac{1 - D^*(y)}{D^*(y)} \approx -\mathbb{E}_{y \sim q_G} \log \frac{D_\psi(y)}{1 - D_\psi(y)} \quad (\text{论文式 “18-20”})$$

原文大意（意译）

中间等号把 D^* 的表达式反解 $q_G/p_Y = (1 - D^*)/D^*$ 后代入；最后一步用训练出的判别器 D_ψ 近似 D^* 。末端表达式恰好就是式 (10) 中生成器最小化的目标——所以在“判别器每步训到最优且唯一”的假设下，生成器的更新就是在对 $\text{KL}[q_G \parallel p_Y]$ 做梯度下降。该假设的现实性正是附录 C 的主题。

🔍 **逐项拆解** ▶ $a \log t + b \log(1 - t)$ 的极值一行验证：求导 $a/t - b/(1 - t) = 0 \Rightarrow t = a/(a + b)$ 。整个证明只有两个机关：① 最优判别器是“真假密度的比例”；② 对数几率 $\log D/(1 - D)$ 在最优值恰好等于 $\log p_Y/q_G$ ——判别器的 logit 就是对数似然比的估计器。这句话是理解一切“GAN 当密度比估计器用”文献的万能钥匙。

附录 B：伪逆的数值求解与梯度（式 21-25）

原文大意（意译）

A 实现为固定高斯核的步长卷积； A^+ 实现为转置卷积，参数 B 用 SGD 最小化 $\ell_1(B) = \mathbb{E}_y \|Ay - ABAy\|_2^2$ 与 $\ell_2(B) = \mathbb{E}_x \|Bx - BABx\|_2^2$ 之和（ y, x 取标准高斯随机向量）——这是对“ $A - ABA$ 与 $B - BAB$ 的谱范数”的蒙特卡洛估计，可当作一个三层全线性卷积网络（ A 固定、 B 可训）来训练。收敛时 $\ell_1 + \ell_2$ 在 10^{-12} 到 10^{-8} 之间。注意某些下采样核的精确 A^+ 具有无限大的核，只能用局部核近似。梯度方面（式 24-25）：投影后模型对 θ 的梯度等于 $(I - A^+A) \frac{\partial g_\theta}{\partial \theta}$ ——即普通梯度的高通滤波版本。

💡 **人话直觉** ▶ 两条 Moore–Penrose 性质 $ABA = A$ 、 $BAB = B$ 被直接翻译成了两个可微损失——“定义即目标函数”，简洁漂亮。梯度=高通滤波也呼应了直觉：低频由 A^+x 包办，网络的学习信号天生只含高频。

附录 C：实例噪声的病理学（含 Figure 6）

原文大意（意译）

考察一个理想化 GAN 算法：每轮①把判别器 D 训到收敛；②从 D 提取对数似然比估计 $s(y) = \log q_\theta(y)/p_Y(y)$ ；③对 $\mathbb{E}_{y \sim q_\theta} s(y)$ 做一步梯度更新。若两分布在低维空间中良态，这就是对 KL 的梯度下降，应当收敛。它在实践中失败依赖三个假设的破产：(1) 对数似然比有限；(2) JS 散度是 θ 的良态函数；(3) 逻辑回归的贝叶斯最优解唯一。当 q_θ 与 p_Y 集中且支撑不重叠时——图像建模中几乎必然如此——(1) KL 无穷；(2) JS 饱和、局部常数；(3) 存在一大类损失接近最优的判别器，每个给生成器的梯度都不同，训练随初始化漂移。常见缓解手段是“削弱判别器”：少训几步、或加标签噪声/单边标签平滑。但 Figure 6b 显示标签平滑只是抬高了所有分类器的损失，**近优判别器集合依然又大又杂**——若贝叶斯最优分类器本就不唯一，标签平滑无济于事。实例噪声 (Figure 6c) 改为给样本加噪：两分布的支撑同时变宽、开始重叠，最优判别器变得唯一、判别器因训练分布更宽而更难拟合、对数似然比变得良态、加噪后的 JS 不再是 θ 的常数。若 p_σ 为高斯，则 d_σ 是 Bregman 散度，且为 0 当且仅当两分布相等。附带的工程红利：不必再担心“把 D 训过头”，每轮可以放心多训判别器。噪声调度是关键超参：本文用加性高斯噪声、按“保持最优判别器损失恒定”的启发式退火；重尾或 spike-and-slab 噪声可能更好，但未测试。

⚠ **易错点** ▶ 注意因果顺序：不是“加噪声让 GAN 碰巧变稳”，而是先**诊断**（三个假设破产）后**开药**（逐条修复）——这正是这节比多数“炼丹技巧”论文更有分量的原因。与扩散模型的区别再强调一次：这里加噪是为了修判别器的病，不构成生成过程。

附录 D/E：训练细节与两个落败者的“尸检”（Figure 7）

原文大意（意译）

D 补充的关键细节：软约束模型的额外损失是 $\ell_{\text{MAE}} = \frac{1}{N} \sum_i \|x_i - A\hat{y}_i\|$ ；DAE 预训练最小化 $\|y - f_{\text{DAE}}^\sigma(y + \varepsilon)\|^2$ （式 27），期间退火 σ 并连续保存参数；训练生成器时按式 (28–30) 用 DAE 梯度做上升，且不断加载更低噪声水平的 DAE 参数——早期用大噪声版本（方向粗、覆盖广），后期用小噪声版本（贴近流形、方向准）。密度模型按链式分解最大化似然（式 31），生成器则最小化生成样本在其下的负对数似然（式 32）。

E 的尸检结论：Figure 7 显示 AffDG / AffLL 的 PSNR、SSIM 都在收敛——模型没有崩，只是收敛到糊的解；AffDG 曲线的台阶状正是“换用更低噪声 DAE”留下的痕迹。两者难点同源：AffDG 的梯度在大小噪声之间两难（准 vs 广），退火不慎就发散；AffLL 则因为准确的密度模型在数据流形附近极度尖锐，训练初期几乎拿不到有用梯度。密度模型本身达到 -4.10 bits/dim（与 Theis & Bethge 2015 在纹理数据上的结果相当，是合格的密度模型），但 AffLL 的模糊输出在它之下拿到了 > -3.5 的高似然——**连糊图都给高分**，说明它对 p_Y 的刻画不够精确，当不了可靠的打分器。

💡 **人话直觉** ▶ bits/dim 小知识：密度模型常用“平均每维多少比特”报告负对数似然（越接近 0 越好，此处为负值记法则越大越好）。“糊图也拿高分”这个现象值得记住——**似然高不等于感知质量好**，这也是后来大家意识到“似然与样本质量脱钩”的早期证据之一。

附录 F：随机版 AffGAN = 摊销变分推断（式 36–47）

原文大意（意译）

给生成器在 LR 输入之外再喂独立噪声 $z \sim p_Z$ ，输出 $\hat{y} = \Pi_x^A f_\theta(x, z)$ 。定义三个分布：边缘 $q_{Y;\theta}$ （对 x, z 都平均）、条件 $q_{Y|X;\theta}$ （固定 x 、只对 z 平均）、联合 $q_{X,Y;\theta} = p_X \cdot q_{Y|X;\theta}$ 。关键一步：**因为仿射投影保证 x 与 $\hat{y}$ 恒一致**，联合分布中“给定 y 时 x 的条件”与真实似然 $p_{X|Y} = \delta(x - Ay)$ 完全相同，于是 $q_{X,Y;\theta} = q_{Y;\theta} \cdot p_{X|Y}$ 与 $= p_X \cdot q_{Y|X;\theta}$ 两种分解同时成立（式 41）。对其应用贝叶斯规则并整理（式 42–46），得到：

$$\arg \min_{\theta} \text{KL}[q_{Y;\theta} \parallel p_Y] = \arg \min_{\theta} \mathbb{E}_{x \sim p_X} \text{KL}[q_{Y|X;\theta} \parallel p_{Y|X}] \quad (\text{论文式 47})$$

原文大意（意译）

左边正是 AffGAN 算法最小化的目标（把边缘输出分布推向真实图像分布），右边是**摊销变分推断**的标准目标：让每个 x 的“近似后验” $q_{Y|X;\theta}$ 逼近真实后验 $p_{Y|X}$ ——而这一切只需要来自 p_Y 与 p_X 的样本。

🔍 逐项拆解 ▶ 式 (47) 的分量在于左右两边“看见的东西”完全不同：左边只涉及**边缘分布**——GAN 判别器只看单张图真不真，从不看配对；右边却是**逐输入的后验匹配**——这是 VAE 式变分推断的核心诉求。等式说明：只要一致性由投影焊死，“训练一个把边缘分布对齐的 GAN”就**自动**在做“把每个条件后验对齐的变分推断”。翻译回应用：同一张低清图配不同的 z ，就能采出多张互不相同、但都严格满足 $A\hat{y} = x$ 的高清解。▶ [幻灯片 32](#)

💡 人话直觉 ▶ 首尾呼应：§ 5.6 的批评（众数非典型 → 应该采样）在这里得到解法雏形；而“从条件分布采样”正是 PRSR 这类自回归方法的思路——两条技术路线在终点汇合。与 VAE 的诚实对比：这里得到的是**近似后验**的样本，不保证真实后验的精确样本。

⚠️ 易错点 ▶ 推导成立的隐含前提仍是那件事：**仿射投影保证一致性**。没有投影（Soft 系），式 (41) 的两种分解不再同时成立，整个“边缘 KL = 平均条件 KL”的等式就断了。可以说投影层在本文里“一鱼三吃”：满足似然约束（§ 3.1）、化归交叉熵（式 9）、支撑变分解释（附录 F）。

终点站·自测清单与配套材料索引

读完自测（答不上就回到对应站）

- ① 为什么 MSE 训练的超分“注定”发糊？（§ 1，贝叶斯最优 = 后验均值）
- ② 式 (7) 的两项各是什么？为何 $Ag_\theta(x) = x$ 对任意 θ 成立？（§ 3.1）
- ③ A^+ 是怎么得到的？它是 $A^\top$ 吗？ A 本身被训练吗？（§ 3.1、附录 B、§ 5.2）
- ④ 式 (9) 为什么说明“不再需要成对数据”？ q_θ 是什么分布？（§ 3.1 续）
- ⑤ GAN 实际最小化的散度与交叉熵差在哪一项？这一项带来什么行为？（§ 3.2）
- ⑥ 实例噪声治的是什么病？为什么单边标签平滑治不了？（§ 3.2.1、附录 C）
- ⑦ “去噪残差 $\div \sigma^2 \approx \text{score}$ ”的适用条件是什么？训练时怎么处理？（§ 3.3）
- ⑧ Table 1 里哪两个数字证明“硬投影优于软约束”？（§ 5.1）
- ⑨ Table 2 里 PSNR 最高的是谁？这与“AffGAN 视觉最好”矛盾吗？（§ 5.4）
- ⑩ “蛇变水”说明方法的什么性质？什么场景要警惕？（§ 5.5）
- ⑪ MAP 的两个原则性缺陷分别是什么？各用什么例子论证？（§ 5.6）
- ⑫ 式 (47) 左右两边各是什么目标？等式成立靠什么前提？（附录 F）

■ 论文章节 ↔ 配套材料对照

论文位置	幻灯片	本稿站点
标题/摘要	第 1-2 页	第 0 站
§ 1 引言 + Figure 1	第 4-8 页	第 1 站
§ 2 相关工作	第 16 页 (对比 SRGAN)	第 2 站
§ 3 理论 (式 1-9)	第 10-14 页	第 3 站 3.0-3.1
§ 3.2 AffGAN + 实例噪声	第 15-19 页	第 3 站 3.2-3.2.1
§ 3.3-3.4 AffDG / AffLL	第 20-22 页	第 3 站 3.3-3.4
§ 4- § 5.5 实验	第 23-28 页	第 4-5 站
§ 5.6 批评 + § 6 结论	第 30、33 页	第 5 站 5.6、第 6 站
附录 A-F	第 18、19、31、32 页	第 7 站

—— 全稿完 · 配套: AffGAN_zh.pdf (逐句译文) · index.html (34 页幻灯片) · 演讲稿_朗读版.md · 快速入门.html